

# 基于时移多尺度注意斜率熵和 SCA-SCN 的风机齿轮箱故障诊断

王荐生, 石凯东, 张婷婷, 王斌, 吴凤娇\*

(西北农林科技大学 水利与建筑工程学院, 陕西杨凌 712100)

**摘要:**行星齿轮箱是风电机组传动链上的重要设备。为提高对齿轮箱不同工作状态下振动信号的识别精度,提出了基于时移多尺度注意斜率熵和改进随机配置网络的故障诊断方法。首先,针对斜率熵需要依据先验知识调整参数,难以实现最优设定,而注意熵忽略了时间序列振幅信息的缺陷提出了注意斜率熵方法。同时,针对传统多尺度熵粗粒化不足的问题,比较了多种改进的多尺度方法,提出了时移多尺度注意斜率熵(TSMASE)。通过在仿真平台的数据上的实验,证明了本文提出的振动信号特征提取方法的有效性、抗噪性和在短时序长度上的鲁棒性。然后,将 TMSAE 提取的特征输入利用正余弦算法(SCA)改进的随机配置网络(SCN)模型,完成 TSMASE-SCA-SCN 模型的构建。研究结果表明模型具有良好的分类效果,在齿轮箱数据集的上诊断准确率达到 99.80%。

**关键词:**注意斜率熵;正余弦算法;随机配置网络;风力发电机组;故障诊断

**中图分类号:**TK83;TH132.425;TP183

## Wind Turbine Gearbox Fault Diagnosis Based on Time-Shift Multi-scale Attention-based Slope Entropy and SCA-SCN

WANG Jiansheng, SHI Kaidong, ZHANG Tingting, WANG Bin, WU Fengjiao

(Northwest A&F University, Yangling Shaanxi 712100, China)

**Abstract:** Planetary gear box is an important equipment in wind turbine drive train. In order to improve the recognition accuracy of vibration signal of gearbox under different working conditions, a fault diagnosis method based on Time-Shift Multi-scale Slope-based Attention Entropy (TSM) and improved Stochastic Configuration Network (SCN) was proposed. Firstly, to overcome the drawbacks that the parameters of slope entropy need to be adjusted according to prior knowledge, which is difficult to achieve the optimal setting, and the attention entropy ignores the amplitude information of time series, the attention-based slope entropy was developed. At the same time, to solve the problem of insufficient coarse granulation of traditional multi-scale entropy, this work compared multiple improved multi-scale methods, and developed the Time-Shift Multi-scale Attention-based Slope Entropy (TMASE). The effectiveness, noise resistance and robustness on short time length of the proposed feature extraction method are proved by experiments on the simulation platform data. Then, by inputting the features extracted from TMASE into the SCN model improved by Sine Cosine Algorithm (SCA), the

**基金项目:**国家自然科学基金重点项目(52339006);国网浙江省电力有限公司双创项目(23-JS-003)

**作者简介:**王荐生(2002-),男,本科生,研究方向为机械设备故障诊断。E-mail:wjs20020511@163.com

**通信作者:**吴凤娇,女,博士,副教授,主要研究方向为水电-新能源发电设备状态监测及故障诊断与优化调度。E-mail:fjwu@nwsuaf.edu.cn

TMASE-SCA-SCN model was constructed. The results show that the model has a proposing classification effect, and the diagnostic accuracy reaches 99.80% on gear box data sets.

**Keywords:** Attention-based slope entropy; Sine cosine algorithm; Stochastic configuration network; Wind turbine; Fault diagnosis

## 0 前言

风机齿轮箱作为风力发电机组传动系统的关键设备,长期工作在高负载强冲击的恶劣工况下,极易发生故障<sup>[1]</sup>,是影响机组可靠性的主要原因。因此开发准确及时的风机齿轮箱故障诊断方法对机组的长期可靠运行具有重要意义。振动信号是设备状态信息的载体,但风机齿轮箱内部结构复杂,背景噪声大,尤其是在故障早期的冲击非常微弱,故障信号容易被强噪声掩盖<sup>[1]</sup>,具有非线性非平稳的特征。因此,传统的将非平稳信号分解为平稳信号之和的方法具有较大的局限性<sup>[2]</sup>,需要使用合适的非线性分析方法。

熵是衡量时间序列复杂度的一种非线性分析方法,在基于振动信号的机械故障诊断领域得到了广泛应用<sup>[3]</sup>。目前常见的熵方法主要有近似熵、模糊熵、排列熵等。在2019年,David Cuesta-Frau提出了一种使用时间序列中相邻数据样本差值编码序列的斜率熵方法,但由于需要的基于先验知识预先设置的参数较多,导致泛化性能较差。而注意熵仅关注序列峰值点的间隔,具有超参数少,运行效率高等优点。但由于忽略了信号的幅值差异,造成了有效信息的丢失。

本文受斜率熵通过对连续数据差值进行复杂度分析的思想启发,提出了基于注意熵方法的改进斜率熵(Attention-based Slope Entropy, ASE),不仅具有注意熵超参数少,计算效率高的优点,而且充分利用了序列振幅差异所包含的信息。通过比较多种多尺度粗粒化方法的优劣,最终提出了一种基于时

移多尺度注意斜率熵(Time-Shift Multi-scale Attention-based Slope Entropy, TSMASE)和改进随机配置网络的风机齿轮箱故障诊断模型(TSMASE-SCA-SCN)。仿真实验的结果表明,TSMASE具有良好的抗噪性能和对短时序长度的鲁棒性,有效地反映了时间序列的特征,建立的TSMASE-SCA-SCN模型具有理想的故障诊断效果,对基于振动特征的风机齿轮箱故障诊断具有理论和现实意义。

## 2 时移多尺度注意斜率熵

### 2.1 注意熵

不同于传统的特征提取算法关注时间序列中所有数据的概率分布,注意熵仅关注序列中的关键观测值,通过提取关键模式,计算其间隔来对序列进行符号化处理。

对于时间序列 $\{x_n\} = x_1, x_2, \dots, x_n$ ,注意熵将序列的峰值点则作为潜在的关键模式。其中两个峰值点之间的间隔分为四种情况 $\{\min-\min\}$ 、 $\{\min-\max\}$ 、 $\{\max-\min\}$ 和 $\{\max-\max\}$ ,  $\min$ 和 $\max$ 分别表示局部最小值和最大值。综合四种情况有效地平滑了数据中可能出现的异常,使注意熵能够更好地处理较短的时间序列<sup>[4]</sup>。计算流程如下:

(1) 以关键模式 $\{\min-\min\}$ 为例,查找序列的局部最小值,计算相邻局部最小值的间隔 $y_i$ ,由关键模式的间隔长度构成一组维数为 $m-1$ ( $m$ 为局部最小值的个数)的序列 $\{y_{m-1}\} = y_1, y_2, \dots, y_{m-1}$ 。

(2) 计算间隔序列 $\{y_{m-1}\}$ 的香农熵。

$$H(y) = -\sum_{i=1}^b p(z_i) \log_2 p(z_i) \quad (1)$$

$b$ 为 $\{y_{m-1}\}$ 中不同间隔长度的种类数,  
 $p(z_i)$ 为间隔长度 $z_i$ 出现的频率。

(3) 将 4 种不同策略求解得到的香农熵的均值定义为该振动信号的注意熵。




图 1 注意熵计算流程图

Fig.2 Flow chart of attention entropy

## 2.2 斜率熵

斜率熵基于两个设置的阈值对时间序列中连续数据样本的差值进行离散化处理, 得到嵌入向量的符号表示<sup>[5]</sup>。对于由 $n$ 个数组成的时间序列 $\{x_n\} = x_1, x_2, \dots, x_n$ , 具体计算过程如下:

(1) 对序列进行相空间重构, 得到一组维数为 $m$ 的嵌入向量 $X_1, X_2, \dots, X_{n-m+1}$ , 其中  $X_i = \{x_i, x_{i+1}, \dots, x_{i+m-1}\}, 1 \leq i \leq n - m + 1$ , 代表从 $x_i$ 开始的 $m$ 个连续值。

(2) 计算嵌入向量中连续样本的差值 $x_{i+1} - x_i$ , 构成维数为 $m - 1$ 的新序列 $Y_i = \{y_i, y_{i+1}, \dots, y_{i+m-2}\}$ 。

(3) 使用给定的阈值 $\delta, \gamma$ 将嵌入向量差值构成的差值序列进行离散化处理, 得到相应的符号模式。对于差值 $x_{i+1} - x_i$ 的符号分配规则如下:

- 如果 $x_{i+1} > x_i + \gamma$ , 符号为+2
- 如果 $x_i + \delta < x_{i+1} \leq x_i + \gamma$ , 符号为+1
- 当差值在 0 附近, 即 $|x_{i+1} - x_i| \leq \delta$ ,

则分配的符号为 0。

- 如果 $x_i - \gamma \leq x_{i+1} < x_i - \delta$ , 符号为-1
- 如果 $x_{i+1} > x_i - \gamma$ , 符号为-2

(4) 基于符号模式计算香农熵, 得到时间序列的斜率熵。

## 2.3 注意斜率熵

斜率熵虽然具有较高的计算效率和较强的信号表征能力, 但是其符号化方法具有较大的改进空间。尤其是由于阈值参数 $\delta$ 和 $\gamma$ 需要根据先验知识进行手动调整, 造成斜率熵超参数过多, 泛化能力较差。

本文将斜率熵视作一种将时间序列转换为其连续数据的差值构成的新序列, 然后使用熵方法进行复杂度分析的思想。由此, David Cuesta-Frau 提出的斜率熵方法实际上是使用散布熵<sup>[6]</sup>计算差值序列的熵值, 在符号化方法上采用给定的阈值对数据进行离散化处理。基于此, 本文提出使用注意熵计算所得的差值序列的复杂度, 可以在保证计算效率的前提下, 提高泛化能力, 避免了像斜率熵一样手动调整大量的超参数; 而且, 由于差值序列的应用, 弥补了注意熵忽略振幅之间差异所包含的信息的缺陷。

为提高注意斜率熵的抗噪性, 本文在注意斜率熵中应用的注意熵方法还增加了一个阈值参数 $\epsilon$ , 只有当相邻的极大值和极小值之间的差值大于该阈值时才将其考虑为有效的极值。阈值的计算方法如下:

$$\text{threshold} = \epsilon \times \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2} \quad (2)$$

其中 $\{x_n\} = x_1, x_2, \dots, x_n$ 表示由原始时间序列相邻数据的差得到的差值序列

## 2.4 时移多尺度注意斜率熵

本文提出的注意斜率熵方法只反映了

时间序列在单一尺度上的信息,因此基于分形理论引入了时移多尺度熵的方法来反映时间序列在不同尺度下的相似性和复杂度。

TSMASE 具体计算过程如下:

(1) 对于由  $n$  个数据组成的原始时间序列  $\{x_n\} = x_1, x_2, \dots, x_n$ , 当尺度因子为  $\tau$  时, 定义  $y_{k,\beta}$  为:

$$y_{k,\beta} = \{x_k, x_{\beta+k}, x_{2\beta+k}, \dots, x_{\Delta_{(k,\beta)}\beta+k}\} \quad (3)$$

式中:  $k(1 \leq k \leq \tau)$  和  $\beta(\beta = \tau)$  是正整数, 分别表示子序列的起点和间隔时间。  $\Delta_{(k,\beta)}$  为不超过  $\frac{N-k}{\beta}$  的最大整数

(2) 计算序列  $y_{k,\beta}$  相邻数据的差值得到相应的维数为  $\Delta_{(k,\beta)} - 1$  的差值序列, 并计算差值序列的注意熵, 得到时移子序列  $y_{k,\beta}$  的注意斜率熵。

(3) 对得到的  $\tau$  个时移子序列的注意斜率熵求均值, 得到尺度因子  $\tau$  下的时移多尺度注意斜率熵, 即

$$TSMASE(X, \tau, \varepsilon) = \frac{1}{\tau} \sum_{k=1}^{\tau} TSASE(y_{k,\beta}^{(\tau)}, \varepsilon) \quad (4)$$

其中,  $\varepsilon$  表示阈值参数。

### 3 正余弦算法改进的随机配置网络

#### 3.1 随机配置网络

随机配置网络 (Stochastic Configuration Network, SCN)<sup>[7]</sup> 是一种增量式的单隐藏层前馈神经网络, 可以根据训练效果自适应地构建隐藏层结构, 如图 2 所示。SCN 通过监督机制随机配置每个隐含层节点的输入权值和偏置, 逐渐增加隐含层节点个数, 并利用最小二乘法确定网络的输出权重, 从而完成神经网络模型的构建<sup>[8]</sup>。




图 2 随机配置网络结构

Fig.2 Structure of stochastic configuration network

#### 3.2 正余弦算法

正余弦算法 (Sine Cosine Algorithm, SCA) 是 2016 年提出的一种基于正余弦函数的群智能优化算法<sup>[9]</sup>, 具有寻优性能好、结构简单、易于实现等优点。

该算法首先随机生成多个候选解, 利用正余弦函数的波动性和周期性不断迭代更新解的位置, 搜索空间中的不同区域, 使得其解最终可以收敛于全局最优<sup>[10]</sup>。其搜索过程分为全局探索和局部开发两个阶段, 在全局探索阶段, 优化算法快速搜索空间中的可行区域; 到了局部开发阶段, 随机解迭代变化的速度会明显低于全局探索阶段<sup>[11]</sup>。

#### 3.3 TSMASE-SCA-SCN 模型

本文提出的 TSMASE-SCN-SCA 模型风机齿轮箱故障诊断流程如图 3 所示。首先使用 TSMASE 提取振动信号的特征, 然后基于 SCA 算法优化 SCN 的预设误差  $\varepsilon$ , 最大节点数  $L_{max}$  和候选节点数  $T_{max}$  三个参数, 将模型预测准确率作为损失函数训练 SCA-SCN 模型, 最后将振动信号的特征输入到 SCA-SCN 模型中进行故障模式识别。




图3 TMASE-SCA-SCN 模型风机故障诊断流程图

Fig.3 Flow chart of wind turbine gearbox fault diagnosis model TMASE-SCA-SCN

## 4 风机齿轮箱故障诊断实验

### 4.1 实验流程与参数设置

本实验分别对噪声仿真信号和风机齿轮箱实际运行数据进行了分析。

在仿真信号分析中，将时移多尺度与复合多尺度和多尺度注意斜率熵提取的特征进行了比较，分析不同多尺度方法在噪声和短时序长度上的鲁棒性；并与时移多尺度注意熵和斜率熵进行了对比，比较了注意斜率熵与原注意熵和斜率熵方法的优劣。

在风机齿轮箱故障诊断试验中，除了分析三种多尺度斜率注意熵方法提取的特征结果。同时还选用斜率熵、注意熵、符号熵和排列熵与本文提出的斜率注意熵的特征提取效果进行了比较。其中所有多尺度熵的最大尺度因子均设置为20。本文中涉及的名词缩写命名规则如表1。

表1 专业名词缩写

Tab.1 Abbreviation of technical nouns

名词缩写	全称
MASE	多尺度斜率注意熵
CMASE	复合多尺度斜率注意熵
TSMASE	时移多尺度斜率注意熵
TSMSE	时移多尺度注意熵
TSMSP	时移多尺度斜率熵
TSMSE	时移多尺度符号熵
TSMPE	时移多尺度排列熵

在向风机齿轮箱实际运行数据加入噪

声时，首先对振动信号进行归一化，将幅值映射到 $[-1,1]$ 的区间，然后加入不同信噪比（SNR）的高斯白噪声<sup>[12]</sup>，训练SCN和SCA-SCN模型。信噪比的计算公式如下<sup>[13]</sup>：

$$R = \lg\left(\frac{S}{N}\right) \quad (5)$$

其中， $R$ 为SNR的值， $S$ 为信号功率， $N$ 为噪声功率。

在参数设置上，斜率熵的嵌入维数设置为3，阈值 $\delta$ 、 $\gamma$ 分别设置为0.001和1；注意熵和注意斜率熵的阈值参数 $\varepsilon$ 设置为0.1；本文使用的符号熵<sup>[14]</sup>将序列最大值与最小值的差值区间平均分为十份对数据进行符号化处理；排列熵<sup>[15]</sup>的嵌入维数同样设置为3。对于SCN模型，根据经验，将预设误差 $\varepsilon$ 设置为0.001，最大节点数 $L_{max}$ 设置为50，候选节点数 $T_{max}$ 设置为200。对于使用的SCA优化算法，种群数量设置为10，最大迭代次数设置为20，参数 $a$ 设置为2。

完整的实验流程如图4所示。

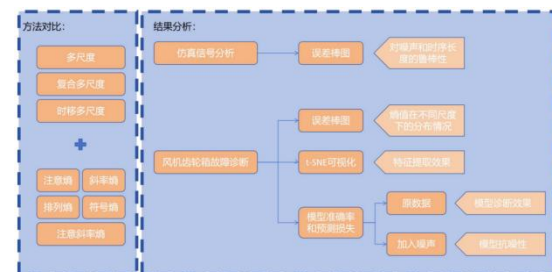


图4 实验流程图

Fig.4 Flow chart of the experiment

### 4.2 仿真信号分析

为了研究本文提出的TSMASE的性能，尤其是其对于噪声和短时序长度的鲁棒性，对非平稳的有色噪声信号进行了特征提取并分析。有色噪声功率谱密度函数一般可以写为 $1/f^\alpha$ 。随着 $\alpha$ 的增加，噪声信号中会含有更多的低频成分。其中红噪声（red noise）的功率谱密度函数中 $\alpha = 2$ ，是最严重的一



种非平稳有色噪声<sup>[16]</sup>，在本节中作为噪声仿真信号用于对 TSMASE 方法鲁棒性的分析。

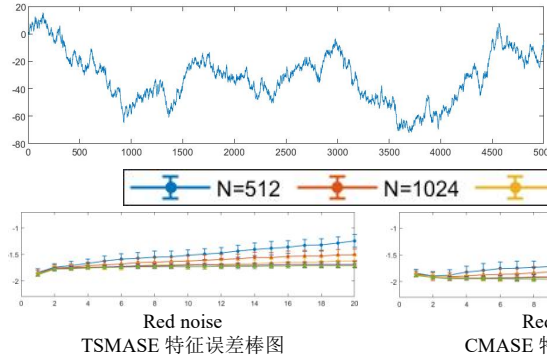


图 5 红色噪声信号

Fig.5 Signals of red noise

如图 6, 为 TSMASE、CMASE 和 MASE 提取的红噪声特征分布情况。其中五种序列长度均选择了 100 个样本进行分析。

图 6 不同多尺度注意斜率熵特征分布情况

Fig.6 Feature value distribution of different multi-scale attention-based slope entropy

从不同时序长度红噪声信号的特征分布差异上可以看到，斜率注意熵的三种多尺度粗粒化方法中，TSMASE 方法提取的不同时序长度的信号特征分布差异最小，对时序长度变化，尤其是短时序长度具有较强的鲁棒性。

上的分布情况可以看到，MASE 提取的特征随尺度因子变化波动较大，抗噪性较差；而 TSMASE 和 CMASE 的特征分布则较为稳定，说明对噪声具有较好的鲁棒性。

图 7 为 TSMASE 和 TSMSPE 在红噪声上提取的特征的分布情况。

从红噪声信号的特征在不同尺度因子




图 7 不同时移多尺度熵特征分布情况

Fig.7 Feature value distribution of different time-shift multi-scale entropy

TSMSPE 随着时序信号长度的减小变化较大，不同尺度因子的熵值差异也较大，对短时序长度和噪声的鲁棒性较差。红噪声信号长度不同，TSMASE 提取的特征分布差异更大，在较高尺度上尤为明显。不仅随时序长度的减小，特征分布产生了较大的偏移，而且对于同一时序长度的噪声信号，在不同尺度因子下的差异也更大。说明与 TSMASE 相比其对低频成分较多的红噪声鲁棒性较差。实验结果说明了 TSMASE 相比于 TSMASE 和 TSMSPE 具有更好的抗噪性和对短时序长度的鲁棒性。

#### 4.3 风机齿轮箱故障诊断

本节采用的齿轮故障数据来自北京交通大学的风力发电传动链试验台行星齿轮箱数据集<sup>[17]</sup>。在本节中，选用其第一次试验数据中装置在 x 方向上的振动信号进行分析，采样频率为 48 kHz。从时域信号的第一个数据点开始，每连续的 2048 个数据点作为一个样本，每类故障下各取 200 个样本用于齿轮故障诊断试验。不同工作状态下测得的振动信号如图 8 所示。

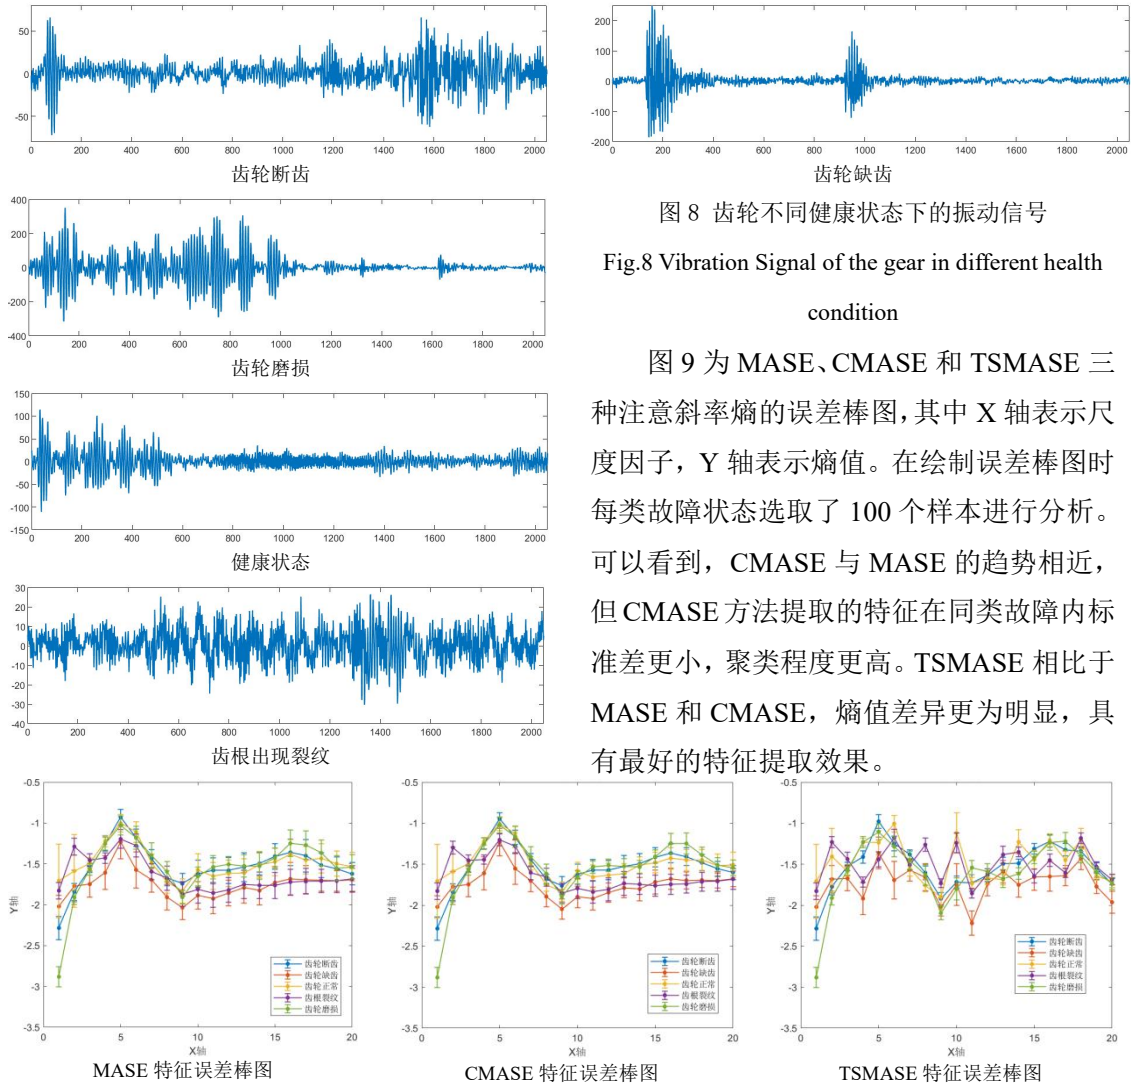


图 8 齿轮不同健康状态下的振动信号

Fig.8 Vibration Signal of the gear in different health condition

图 9 为 MASE、CMASE 和 TSMASE 三种注意斜率熵的误差棒图,其中 X 轴表示尺度因子, Y 轴表示熵值。在绘制误差棒图时每类故障状态选取了 100 个样本进行分析。可以看到, CMASE 与 MASE 的趋势相近,但 CMASE 方法提取的特征在同类故障内标准差更小,聚类程度更高。TSMASE 相比于 MASE 和 CMASE,熵值差异更为明显,具有最好的特征提取效果。




图 9 不同多尺度注意斜率熵特征分布情况

Fig.9 Feature value distribution of different multi-scale attention-based slope entropy

图 10 为四种时移多尺度熵特征提取方法的误差棒图。可以看到, TSMSE 和 TSMSE 提取的特征除齿轮磨损状态外均有较大程度的重叠,难以区分; TSMSE 在部分尺度上有较为明显的差异。TSMSE 则与 TSMASE 相近,对齿轮五种健康状态下的振动信号都有较为明显的差异,具有较好的区分度,需要进一步分析才能区分。





图 10 不同时移多尺度熵特征分布情况

Fig.10 Feature value distribution of different time-shift multi-scale entropy

为了更好的比较不同熵特征提取方法,利用 t-分布随机邻域嵌入 (t-distributed Stochastic Neighbor Embedding, t-SNE) 对提取的特征降维,进行可视化分析,结果如图 11 所示。可以看到在三种多尺度方法中,

TSMASE 混叠程度最小，类别辨识度最高，有效地区分了齿轮五种状态下运行的振动信号，而 MASE 和 CMASE 提取的特征都发

生了较大程度的混叠，无法完全区分出齿轮的不同状态。




图 11 不同多尺度注意斜率熵特征提取的可视化结果

Fig.11 Feature visualization result of different multi-scale attention-based slope entropy

如图 12，为 TSMSE、TSMPE、TSMSPe 和 TSMaE 四种时移多尺度熵特征提取方法的 t-SNE 可视化结果。可以看出在不同熵的特征提取方法中 TSMSE 和 TSMSPe 的特征提取效果最差，混杂程度高，难以区分，TSMPE 与 TSMaE 仅发生了零星的混叠现象，但相比之下，TSMASE 几乎无混叠，且类别之间差异更大，特征提取效果最为理想。

入 SCN 模型和 SCA-SCN 模型，构建和训练风力电机齿轮箱故障诊断模型。

表 2 为采用五折交叉验证得到的不同模型的预测准确率和无噪声数据下的预测损失，其中预测损失为预测标签与真实标签之间的标准差。可以看到，采用 TSMASE 特征进行训练的 SCN 模型准确率最高，尤其是从预测损失上可以观察到 TSMASE 方法具有明显的优势。TSMASE-SCA-SCN 模型对 SCN 模型的关键参数进行了优化，相比于 TSMASE-SCN 模型，在五折交叉验证的结果中，其准确率和标准差均有一定提升，表明了使用 SCA 算法优化 SCN 模型的可行性。

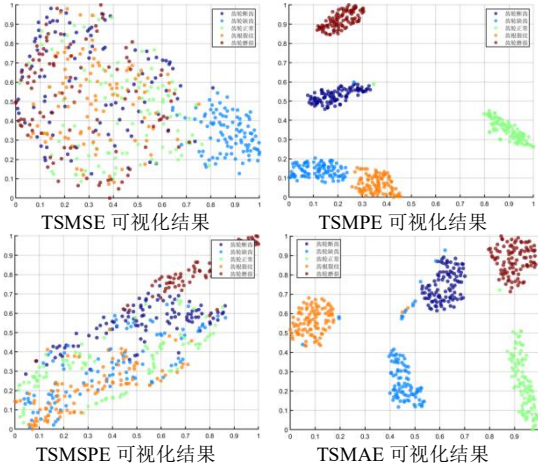


图 12 不同时移多尺度熵特征提取的可视化结果

Fig.12 Feature visualization result of different time-shift multi-scale entropy

将不同时移多尺度熵提取的特征输

入 SCN 模型和 SCA-SCN 模型，构建和训练风力电机齿轮箱故障诊断模型。加入信噪比 SNR=50dB 的高斯白噪声后模型准确率显著下降，但随着信噪比的上升，基于注意斜率熵特征的模型最先达到了较理想的故障识别效果，其中基于 TSMASE 的模型，尤其是 TSMASE-SCA-SCN 模型表现最佳，说明模型具有较强的抗噪性，更适用于低信噪比的风机齿轮箱故障诊断问题。

表 2 基于不同多尺度熵的模型诊断结果

Tab.2 Diagnosis result of models based on different multi-scale entropy

模型	准确率 (%)				标准差
	SNR=50dB	SNR=100dB	SNR=150dB	无噪声	
TSMASE-SCA-SCN	20.7	98.4	99.5	99.8	0.0283



TSMASE-SCN	22.1	98.	99.1	99.5	0.0746
CMASE-SCN	21.4	92.3	93.1	97.2	0.2353
MASE-SCN	21.5	77.5	78.6	90.6	0.4309
TSMAB-SCN	20.5	58.8	60.4	98.9	0.1276
TSMSPE-SCN	46.1	55.8	57.5	85.7	0.5344
TSMSE-SCN	19.2	36.1	35.2	54.5	0.9537
TSMPE-SCN	19.2	77.1	80.5	99.1	0.1013

图 13 为在无噪声数据上使用独立数据集验证得到的基于不同时移多尺度熵的模型混淆矩阵，其中基于 TSMASE 特征的

SCN 和 SCA-SCN 模型预测准确率均达到了 100%，在所有模型中表现最佳，再次说明了 TSMASE 方法的优越性。




图 13 基于不同时移多尺度熵的模型混淆矩阵图

Fig.13 Confusion matrix of models based on different time-shift multi-scale entropy

#### 4 结论

针对强噪声的风力发电机组振动信号，本文提出了 TSMASE-SCA-SCN 模型的风机齿轮箱故障诊断方法，通过实验验证得到以下结论：

(1) 本文将斜率熵抽象为一种对时间序列连续数据差值构成的差值序列应用熵方法进行分析的思想，提出了一种新的时间序列熵值计算方法，注意斜率熵。然后引入时移多尺度方法对时间序列进行粗粒化，使用 TSMASE 进行风机齿轮箱振动信号的特征提取。实验结果表明 TSMASE 在振动信号特征提取效果上具有明显的优势，且对短时序长度和噪声具有较好的鲁棒性。

(2) 应用 SCA 算法对 SCN 模型超参数进行优化，构建了 TSMASE-SCA-SCN 模型用于风电机组齿轮箱故障诊断。结果表明模型具有良好的泛化性能和诊断效果，应用前景广阔。

#### 参考文献

- [1] 蔡昌春，何捷，承敏钢，等. 基于改进 VMD-MCKD 和深度残差网络的风机齿轮箱故障诊断 [J]. 山东电力技术, 2024, 51(02): 67-78.
- CAI C C, HE J, CHENG M G, et al. Fault Diagnosis of Fan Gearbox Based on Improved VMD-MCKD and Deep Residual Network [J]. Shandong Electric Power, 2024, 51(02): 67-78.
- [2] 郑近德，程军圣，杨宇. 多尺度排列熵及其在滚动轴承故障诊断中的应用 [J]. 中国机械工程, 2013, 24(19): 2641-6.
- ZHENG J D, CHENG J S, YANG Y. Multi-scale Permutation Entropy and Its Applications to Rolling Bearing Fault Diagnosis [J]. China Mechanical Engineering, 2013, 24(19): 2641-6.
- [3] 陈东宁，张运东，姚成玉，等. 基于 FVMD 多尺度排列熵和 GK 模糊聚类的故障诊断 [J]. 机械工程学报, 2018, 54(14): 16-27.
- CHEN D N, ZHANG Y D, YAO C Y, et al. Fault Diagnosis Based on FVMD Multi-scale Permutation

- Entropy and GK Fuzzy Clustering [J]. Journal of Mechanical Engineering, 2018, 54(14): 16-27.
- [4] YANG J, CHOUDHARY G I, RAHARDJA S, et al. Classification of Interbeat Interval Time-Series Using Attention Entropy [J]. IEEE Trans Affect Comput, 2023, 14(1): 321-30.
- [5] LI Y, TANG B, JIAO S. Optimized Ship-Radiated Noise Feature Extraction Approaches Based on CEEMDAN and Slope Entropy [J]. Entropy, 2022, 24(9): 1265.
- [6] 赵亚鹏. 波动散布熵在旋转机械故障诊断中的应用研究 [D]. 燕山大学, 2023.
- ZHAO Y P. RESEARCH ON THE APPLICATION OF FLUCTUATION DISPERSION ENTROPY IN FAULT DIAGNOSIS OF ROTATING MACHINERY [D]. Yanshan University, 2023.
- [7] WANG D, LI M. Stochastic configuration networks: Fundamentals and algorithms [J]. IEEE transactions on cybernetics, 2017, 47(10): 3466-79.
- [8] 吉建娇, 王殿辉. 基于区间边界探测的进化随机配置网络 [J]. 控制理论与应用: 1-10.
- JI J J, WANG D H. Boundary-detection-based evolutionary stochastic configuration networks [J]. Control Theory & Applications, 2018, 54(14): 16-27.
- [9] MIRJALILI S. SCA: a sine cosine algorithm for solving optimization problems [J]. Knowledge-based systems, 2016, 96: 120-33.
- [10] 蔡俊, 蔡士超. 基于 SCA-VMD 和排列熵的轴承故障诊断研究 [J]. 黑龙江工业学院学报(综合版), 2023, 23(11): 140-8.
- [11] 战文华, 张国彦, 姜磊, 等. 基于新型调压装置与正余弦算法的电压优化方法 [J]. 电力电容器与无功补偿, 2023, 44(02): 47-54.
- ZHAN W H, ZHANG G Y, JIANG L, et al. Voltage Optimization Method Based on New Voltage Regulator and Sine Cosine Algorithm [J]. Power Capacitor & Reactive Power Compensation, 2023, 44(02): 47-54.
- [12] 王永坚, 胡欢欢, 李品芳. EEMD 能量熵和奇异值熵与 SVM 融合的船用空压机故障诊断 [J]. 上海海事大学学报, 2020, 41(04): 95-102.
- WANG Y J, HU H H, LI P F. Fault diagnosis for marine air compressors by fusion of EEMD energy entropy and singular value entropy with SVM [J]. Journal of Shanghai Maritime University, 2020, 41(04): 95-102.
- [13] 徐坤, 刘征, 朱维超, 等. CWNT 时频尺度多步噪声抑制的轴承故障诊断 [J]. 机电工程技术, 2024, 53(02): 8-12.
- XU K, LIU Z, ZHU W C, et al. Bearing Fault Diagnosis of Multi-step Noise Suppression at CWNT Time-frequency Scale [J]. Mechanical & Electrical Engineering Technology, 2024, 53(02): 8-12.
- [14] 陈子寒. 基于多变量符号转移熵及部分信息分解的抑郁症脑磁图研究 [D]. 南京邮电大学, 2021.
- CHEN Z H. Research on the MEG of Depression Patients based on Multivariate Symbolic Transfer Entropy and Partial Information Decomposition [D]. Nanjing University of Posts and Telecommunications, 2021.
- [15] 储祥冬, 戴礼军, 涂金洲, 等. RCMNAAPE 在旋转机械故障诊断中的应用 [J]. 机电工程: 1-12.
- CHU X D, DAI L J, TU J Z, et al. Application of RCMNAAPE in fault diagnosis of rotating machinery [J]. Journal of Mechanical & Electrical Engineering: 1-12.
- [16] HASSANI S, MOUSAVI M, DACKERMANN U. Johansen cointegration of frequency response functions contaminated with nonstationary colored noise for structural damage detection [J]. Journal of Sound and Vibration, 2023, 552: 117641.
- [17] LIU D, CUI L, CHENG W. A review on deep learning in planetary gearbox health state recognition: Methods, applications, and dataset publication [J]. Measurement Science and Technology, 2023.